

基于机器学习的心力衰竭患者生存预测与风险研究

摘要

针对传统心力衰竭（Heart Failure, HF）风险评估模型难以刻画复杂非线性关系、预测能力有限的问题，本文基于真实世界心衰患者临床随访数据，构建了一套融合统计分析与机器学习的死亡风险预测框架，以实现对患者预后的精准评估与风险分层。研究以 299 例心衰患者的 13 维临床指标为基础，系统完成数据清洗、异常值检测、特征标准化及分层抽样等预处理流程。考虑到医学数据中极端值往往具有重要病理意义，本文采用 **IQR 方法** 识别异常值，但不进行剔除，从而保留高危患者的重要临床信息，并结合 **Z-score 标准化** 降低量纲差异对模型训练的影响。

在**风险因子识别**阶段，本文结合 Pearson 相关性分析与随机森林特征重要性评估，从线性与非线性两个维度挖掘关键危险因素。结果表明，**血清肌酐、射血分数与年龄**是影响心衰患者死亡风险的三大核心指标。其中，血清肌酐在线性相关分析中呈现负相关，但在随机森林中重要性最高，揭示了其潜在的非线性阈值效应；射血分数虽线性相关较弱，但树模型成功捕捉到其分段风险特征，验证了传统线性方法在复杂临床关系建模中的局限性。

在**预测建模**阶段，本文分别构建逻辑回归（Logistic Regression）、随机森林（Random Forest）及 XGBoost 三类模型，并采用准确率、精确率、召回率、F1 分数及 ROC-AUC 等指标进行系统比较。结果显示，**随机森林模型**表现最优，其 AUC 达到 0.7933，准确率为 0.7167，均优于逻辑回归（AUC=0.7522）与 XGBoost（AUC=0.7317）。研究进一步发现，在小样本医学数据场景下，基于 Bagging 策略的随机森林相比 Boosting 结构的 XGBoost 具有更强的泛化能力与鲁棒性。与此同时，随机森林输出的概率值能够有效实现患者风险分层：低、中、高风险组实际死亡率分别为 12.5%、52.2% 和 60.0%，呈现显著单调递增趋势。

此外，本文通过典型患者案例验证了模型的个体化预测能力。模型能够综合年龄、射血分数、血清肌酐及合并症等多维临床特征，输出连续化死亡概率，并与临床病理机制保持高度一致。研究结果表明，融合机器学习与临床解释的心衰死亡风险预测框架不仅提升了模型区分能力，也增强了预测结果的临床可解释性，可为心衰患者的精准分层管理、随访策略制定及医疗资源优化提供可靠的量化决策支持。

关键字：机器学习 心力衰竭 逻辑回归 随机森林 XGBoost 非线性特征 风险分层 生存预测

目录

一、引言	4
二、研究技术路线	4
三、数据准备与预处理	5
3.1 数据来源概述	5
3.2 数据预处理	6
3.2.1 样本描述与临床特征分析	6
3.2.2 数据质量检验	7
3.2.3 数据质量检验	7
3.2.4 特征标准化	8
四、临床风险因子检测与特征选择	10
4.1 分析方法与流程	10
4.2 特征相关性分析	10
4.3 随机森林特征重要性评估	11
4.4 高危因子综合排序与医学解释	12
五、心衰患者死亡概率预测模型的构建与评估	12
5.1 预测模型选择与理论基础	12
5.1.1 逻辑回归：广义线性模型与概率建模	13
5.1.2 随机森林：Bagging 集成与决策树平均	13
5.1.3 XGBoost：梯度提升与二阶优化	14
5.2 数据集划分与模型训练	14
5.3 模型性能评估与对比分析	15
5.3.1 混淆矩阵与基础分类指标	15
5.3.2 ROC 曲线与 AUC 值	16
5.3.3 综合比较与模型优选	16
六、个体化死亡概率预测与风险分层验证	17
6.1 风险分层能力验证	18
6.2 个体化预测示例	18
七、讨论与推广	19

7.1 模型性能的比较与解释	19
7.2 核心风险因子的临床意义	20
7.3 方法学优势与局限	20
7.4 模型的推广与临床转化潜力	21
八、结论	21
参考文献	22

一、引言

心力衰竭（Heart Failure, HF）作为心血管疾病的严重或晚期阶段，具有高发病率、高病死率、高住院率和高昂医疗费用等特点 [1]。在当前人口老龄化加剧与代谢性疾病频发的背景下，降低心衰造成的社会经济负担已成为全球公共卫生领域的优先关注事项。早期且准确的生存风险预测对于及时采取干预措施、优化临床医疗资源配置以及改善患者预后效果具有至关重要的意义 [2, 3]。

传统的风险评估主要基于 Logistic 回归等线性统计模型，尽管其具有较好的可解释性，但在处理大规模医疗数据中的复杂非线性关系时，预测能力往往受限 [4]。随着医疗大数据时代的到来，机器学习（Machine Learning）在处理多变量、高维度的临床记录时展现出显著优势 [5]。相较于传统统计模型，集成学习算法（如随机森林、XGBoost 等）具有更高的模型容量，能够捕捉特征间的深层交互，从而显著提高预测性能 [6]。

本研究旨在构建稳健的心衰患者生存预测框架，通过融合传统统计分析方法与先进的机器学习算法，实现对患者预后的精准评估。具体研究流程如下：首先，对心衰患者医疗记录数据集进行深度清洗与预处理，并实施特征标准化以消除量纲影响。其次，开展风险因子检测与特征工程，利用相关性热力图直观呈现变量间的关联，并结合基于树模型的特征重要性输出，筛选出对患者死亡事件影响最显著的核心指标。在概率预测建模阶段，本研究在严格划分训练集与测试集的基础上，对比了 Logistic Regression、Random Forest 及 XGBoost 等主流机器学习算法的性能进行特征提取。通过准确率（Accuracy）、精确率（Precision）、召回率（Recall）、 F_1 分数及 ROC-AUC 曲线对各模型进行系统化评估。最后，通过典型新患者案例演示模型的实时预测能力，旨在为临床决策提供科学的量化依据。

二、研究技术路线

为系统呈现本研究的整体分析逻辑与实施步骤，图 1 展示了从原始数据到临床决策支持的技术流程图。整个框架分为四个阶段，依次为数据探索与预处理、风险因子发现、预测模型构建与评估，以及临床输出应用。

第一阶段（数据探索与预处理）包括描述性统计分析、缺失值处理、异常值评估、特征标准化及数据集划分。该阶段旨在确保输入数据的质量与一致性，为后续建模提供可靠的数值基础。

第二阶段（风险因子发现）通过相关性分析、统计检验及基于随机森林的特征重要性排序，识别出与心衰患者死亡结局显著相关的核心临床指标。本研究发现血清肌酐、射血分数与年龄为三大关键风险因子，与后续模型输入特征的选择密切对应。

第三阶段（预测建模）采用逻辑回归、随机森林及 XGBoost 三种主流机器学习算法，在训练集上构建死亡概率预测模型。各模型均基于完整的 13 维临床特征（剔除随

访时间) 进行学习, 并利用测试集评估其泛化能力。

第四阶段 (模型评估) 通过 ROC-AUC、精确率、召回率、F1 分数及混淆矩阵对三种模型进行系统比较。随机森林在 AUC (0.7933)、准确率 (0.7167) 等指标上表现最优, 被选为最终预测模型。

临床输出阶段 则基于新患者数据, 经模型推理输出低、中、高三个风险等级的概率值, 从而实现个体化预后评估与分层管理。该技术路线完整覆盖了从原始数据清洗到临床决策支持的全链条, 为本文后续各章节的逻辑展开提供了清晰的顶层视图。




图1 心力衰竭死亡预测研究技术路线图

三、数据准备与预处理

3.1 数据来源概述

本研究所采用的数据集源自真实的心力衰竭临床随访记录。该数据集通过对 299 位患者在观察期内的生理体征、生化指标及生存状态进行系统性追踪, 构建了一个涵盖 13 个关键维度的多维临床特征空间。每一条样本数据均是对患者复杂病理生理状态的客观刻画, 旨在通过真实的医疗轨迹为生存预测模型提供实证支撑。

3.2 数据预处理

高质量的输入数据是构建可靠生存预测模型的前提。本研究对原始数据进行了系统的清洗、检验与处理。以下从样本描述与临床特征、数据完整性评估、异常值检测与处理三个方面展开论述。

3.2.1 样本描述与临床特征分析

数据集的描述性统计结果如表 1 所示。在 299 例样本中, 终点事件 (DEATH_EVENT) 发生率为 32.1% (96 例), 表明数据集具有足够的正负样本平衡性, 适用于生存分析建模。样本的年龄范围为 40 至 95 岁, 平均年龄为 60.83 岁 (标准差 =11.89), 符合心力衰竭在老年群体中高发的流行病学特征。性别分布显示男性占比 64.9%, 略高于女性。

关键临床指标方面, 射血分数 (ejection_fraction) 的均值为 38.08% (标准差 =11.83), 显著低于正常值 (通常为 50% 以上), 反映出纳入患者的病情较为严重。血清肌酐 (serum_creatinine) 均值为 1.39 mg/dL (标准差 =1.03), 最大值达 9.4 mg/dL, 提示部分患者合并肾功能损伤。肌酸磷酸激酶 (creatinine_phosphokinase) 的偏度 (4.46) 与峰度 (25.15) 极高, 表明该变量分布呈现显著的右拖尾特征, 可能存在极端高值。上述多维度的数据异质性为后续捕捉非线性风险因子提供了真实世界的特征基础。

表 1 描述性统计结果

变量名	均值	标准差	中位数	最小值	最大值
age (年龄)	60.83	11.89	60	40	95
anaemia (贫血)	0.43	0.50	0	0	1
creatinine_phosphokinase (肌酸激酶)	581.84	970.29	250	23	7861
diabetes (糖尿病)	0.42	0.49	0	0	1
ejection_fraction (射血分数)	38.08	11.83	38	14	80
high_blood_pressure (高血压)	0.35	0.48	0	0	1
platelets (血小板)	263358.03	97804.24	262000	25100	850000
serum_creatinine (血清肌酐)	1.39	1.03	1.1	0.5	9.4
serum_sodium (血清钠)	136.63	4.41	137	113	148
sex (性别)	0.65	0.48	1	0	1
smoking (吸烟)	0.32	0.47	0	0	1
time (随访时间)	130.26	77.61	115	4	285
DEATH_EVENT (死亡事件)	0.32	0.47	0	0	1

注：样本量 N = 299，所有变量无缺失值。

3.2.2 数据质量检验

数据缺失是医学数据分析中普遍存在的问题，若处理不当可能导致参数估计偏倚或统计效能下降。因此，建模前对数据质量进行了全面审查。经完整性检验，全部 13 个特征字段在 299 条记录中均无缺失值，数据完整率达到 100%。这一高质量的原始数据避免了多重插补或删除等操作可能引入的偏差，所有样本均可直接纳入后续分析。各变量的数据类型与取值范围均符合临床先验知识，未见明显的数据录入错误或逻辑矛盾。这一高质量的数据状态显著降低了预处理阶段的复杂性。




图 2 心力衰竭数据集描述统计

3.2.3 数据质量检验

异常值 (outlier) 是指显著偏离其余观测值分布的数据点，其存在可能源于测量误差、数据录入错误或真实的病理极端表现。若不加以恰当处理，异常值会过度影响模型参数估计 (如线性回归中的系数)，并对基于距离或梯度的学习算法产生不利扰动。为识别连续型特征中的异常值，本研究采用四分位距法 (Interquartile Range, IQR)。该方法不依赖数据呈正态分布的假设，具有较好的稳健性，尤其适用于医学数据中常见的偏态分布。具体而言，对于特征 X ，设其第一四分位数为 Q_1 ，第三四分位数为 Q_3 ，四分位距定义为：

$$IQR = Q_3 - Q_1 \quad (1)$$

满足以下条件之一的观测值即被判定为异常值：

$$x < Q_1 - 1.5 \times IQR \quad \text{或} \quad x > Q_3 + 1.5 \times IQR \quad (2)$$

选择 IQR 法的原因在于：第一，如前文描述性统计所示，肌酸磷酸激酶、血清肌酐等变量的偏度与峰度极高，不满足正态分布，此时基于均值和标准差的 Z -score 方法 (通常要求 $|Z| > 3$ 为异常值) 易受极端值影响而失效；第二，IQR 法仅依赖于数据的位置统计量 (分位数)，对偏态分布具有天然的抗性；第三，系数 1.5 是公认的稳健阈值，能够在保留真实病理变异与剔除测量误差之间取得平衡 [7]。

基于上述准则对 6 个连续型特征进行检测，结果如图所示：肌酸磷酸激酶检出异常值 29 个，血清肌酐检出 29 个，血小板计数检出 21 个，血清钠检出 4 个，射血分数检出 2 个，年龄及随访时间均未检出异常值。这一结果与前文描述性统计高度吻合：偏度越强、分布拖尾越严重的变量，异常值检出数量越多。需要指出的是，这些异常值并非录入错误——例如，血清肌酐高达 9.4 mg/dL 对应的是严重心肾综合征患者，肌酸磷酸激酶极端高值反映急性心肌损伤。若简单删除，将损失反映真实高危人群的关键信息，削弱模型的临床实用性。因此，在心衰临床数据中，部分连续型特征（如肌酸激酶、血清肌酐等）可能存在极端数值。一般而言，异常值常被视为噪声或测量误差而予以剔除。然而，心力衰竭患者的生理指标极端值往往具有重要的病理生理学意义。例如，肌酸激酶的极度升高可能提示心肌损伤的严重程度，直接删除这些样本可能丢失关键预后信息。基于上述考虑，本研究对所有特征均不进行异常值剔除，即保留全部原始样本。

该处理策略与后续模型选择相适应：随机森林和 XGBoost 均属于树模型，其分裂过程基于特征的排序而非具体数值，因此对异常值天然鲁棒，极端值不会对这些模型的预测性能产生明显扰动。逻辑回归虽对特征尺度较为敏感，但经过 Z-score 标准化后，各特征的量纲被归一化，异常值的影响也被控制在合理范围内。



图 3 异常值检测结果

3.2.4 特征标准化

为进一步消除各特征之间量纲差异对模型训练的影响，本研究对全部连续型特征进行了标准化处理。医学数据中不同指标的量纲和数量级差异显著，例如肌酸磷酸激酶以 mcg/L 为单位，其值域可达数千，而射血分数以百分比表示，取值范围仅为 14–80。若

直接使用原始数据进行建模，量纲较大的变量会在距离计算或梯度下降优化中占据主导地位，导致模型对量纲敏感，降低其对小量纲但临床重要性较高特征的关注。此外，对于采用正则化项的模型，标准化能够确保各特征受到同等的惩罚尺度，从而获得有意义的特征选择结果。

本研究采用 Z-score 标准化（亦称零-均值规范化）方法。对于任意连续型特征 X ，设其样本均值为 μ ，样本标准差为 σ ，则标准化后的特征 X' 定义为：

$$X' = \frac{X - \mu}{\sigma} \tag{3}$$

标准化后的新特征 X' 满足均值为 0、标准差为 1 的分布。该变换不改变原始数据的分布形态，仅将数据平移并压缩至统一的尺度空间。值得注意的是，标准化过程应在训练集上计算 μ 和 σ ，然后将相同的变换参数应用于验证集和测试集，以避免数据泄露。由于本研究后续拟采用多种机器学习模型进行生存预测，Z-score 标准化可确保所有连续型特征在模型训练中具有同等的先验重要性。

对全部连续型特征（age, creatinine_phosphokinase, ejection_fraction, platelets, serum_creatinine, serum_sodium, time）应用上述标准化后，各变量的统计特征如表 2 所示。标准化后所有特征的均值均为 0（由于浮点精度，实际输出为接近 0 的极小值），标准差均为 1。偏度与峰度保持不变，与标准化前完全一致，验证了 Z-score 不改变分布形态的数学性质。标准化后的数据将作为后续特征工程与模型输入的最终版本。对于二元分类变量（anaemia, diabetes, high_blood_pressure, sex, smoking），由于量纲本身统一（均为 0/1 编码），故不进行标准化处理，以保留其天然的可解释性。

表 2 标准化后连续型特征的描述性统计

变量	均值	标准差	最小值	中位数	最大值
age	0.00	1.00	-1.75	-0.07	2.87
creatinine_phosphokinase	0.00	1.00	-0.58	-0.34	7.50
ejection_fraction	0.00	1.00	-2.04	-0.01	3.54
platelets	0.00	1.00	-2.44	-0.01	6.00
serum_creatinine	0.00	1.00	-0.86	-0.28	7.74
serum_sodium	0.00	1.00	-5.37	0.09	2.58
time	0.00	1.00	-1.63	-0.20	1.99

注：因浮点运算，均值实际值约为 10^{-16} 量级，此处取 0.00。

四、 临床风险因子检测与特征选择

4.1 分析方法与流程

本研究的核心目标是识别对心力衰竭患者死亡结局（DEATH_EVENT）具有最强预测作用的临床指标，为后续风险分层与治疗决策提供依据。分析流程包括三个步骤：

（1）**相关性分析**：采用 Pearson 相关系数评估各连续/二分类特征与死亡结局的线性关联强度，并绘制热力图以直观展示特征间的共线性及与结局的关系。

（2）**随机森林特征重要性评估**：为避免随访时间（time）带来的因果倒置（随访越长死亡概率越高），模型构建时剔除 time 变量。采用两种重要性指标：

- **MDI (Mean Decrease Impurity)**：基于基尼不纯度的平均减少量，反映特征在决策树分裂中对同质性提升的贡献。
- **Permutation Importance**：通过随机打乱特征值后观察模型预测精度下降程度，评估特征对模型泛化能力的依赖。

（3）**综合排序与医学解释**：整合相关性系数与两种重要性分数，输出前三位高危因子，并结合临床知识给出病理生理学解释。

上述方法互补：相关性分析捕捉线性关系，随机森林能挖掘非线性交互及阈值效应，两者结合可提高因子筛选的稳健性。

4.2 特征相关性分析

为量化各临床特征与死亡结局的线性关联，计算 Pearson 相关系数，并以热力图呈现全特征相关矩阵。图 4 展示了各特征与 DEATH_EVENT 的相关系数，结果汇总于表 3。




图 4 特征相关性热力图

表 3 各特征与死亡事件的 Pearson 相关系数

特征	年龄	贫血	肌酸激酶	糖尿病	射血分数	高血压	性别	吸烟	血小板	血清钠	血清肌酐
r	0.294	0.254	-0.079	-0.066	0.063	-0.002	-0.004	-0.013	-0.049	-0.195	-0.269

注：加粗数值表示绝对值较大的显著相关 ($p < 0.05$)。

结果表明：

- **正向相关：**年龄 ($r = 0.294$)、贫血 ($r = 0.254$) 与死亡风险呈中等强度正相关，提示增龄和贫血是心衰患者不良预后的危险因素。
- **负向相关：**血清肌酐 ($r = -0.269$) 和血清钠 ($r = -0.195$) 与死亡呈负相关，即较低的血清肌酐或血清钠水平与更高死亡风险相关。需要指出，血清肌酐的负相关方向似乎与临床直觉（肌酐升高提示肾损伤，增加死亡风险）相悖。进一步检查原始数据分布发现，个别极端高肌酐值（如 9.4 mg/dL）存活时间极短，而多数死亡病例肌酐处于中等偏低范围，导致线性相关系数呈负向；实际关系可能为 U 型或受混杂因素影响，后续随机森林的非线性模型将更准确刻画其重要性。
- **弱相关：**射血分数 ($r = 0.063$)、高血压、糖尿病等与死亡事件的线性相关极弱，但并不意味着它们不重要——可能表现为非线性或依赖于其他特征的交互作用。

完整特征相关矩阵（下三角）显示各特征间共线性较低（多数 $|r| < 0.2$ ），适合采用树模型进行重要性评估。

4.3 随机森林特征重要性评估

基于随机森林算法，以 DEATH_EVENT 为目标变量，输入除 time 外的所有特征。分别计算 MDI 和 Permutation 重要性，结果如图所示。




图 5 随机森林特征重要性结果图

两种重要性指标高度一致：血清肌酐、射血分数、年龄位列前三，且显著高于其余

特征（MDI 中前三者之和占比 > 45%）。值得注意的是，血清肌酐在相关性分析中呈负相关，但在随机森林中重要性最高，说明其对死亡风险的预测能力并非简单的线性关系，可能涉及阈值效应（如肌酐 > 1.5mg/dL 时风险剧增）或与其他特征的交互（如与年龄、射血分数共同作用）。射血分数在相关性中几乎为零，但在重要性排序中位居第二，验证了其作为心衰核心病理生理指标的价值——线性相关被其他因素掩盖，而树模型成功捕捉了其分段效应（如射血分数 < 30% 时死亡风险显著升高）。

4.4 高危因子综合排序与医学解释

综合 Pearson 相关系数、MDI 和 Permutation 重要性，确定**血清肌酐、射血分数、年龄**为心力衰竭患者死亡的三大核心风险因子。其临床意义及机制解释如下：

1. **血清肌酐**：肌酐是肌肉代谢产物，经肾小球滤过排泄。心衰时心输出量下降导致肾灌注不足，引起肾功能恶化（心肾综合征）。本研究中血清肌酐中位数为 1.1 mg/dL，但死亡组中分布更分散且存在极端高值。肌酐升高提示肾灌注受损及神经内分泌过度激活（RAAS、交感神经），与不良预后直接相关 [8]。随机森林将其列为最重要因子，提示临床应密切监测肾功能。

2. **射血分数**：反映左心室收缩功能，正常值 $\geq 50\%$ 。本研究患者射血分数中位数 38%，符合射血分数降低的心衰（HFrEF）特征。每收缩一次心脏泵出的血液百分比越低，组织灌注越差，代偿性心率增快和心肌耗氧增加，最终进展为心源性死亡。尽管线性相关弱，但随机森林识别出其非线性阈值效应（例如 $\leq 30\%$ 风险骤升），符合临床指南将 HFrEF 定义为射血分数 $\leq 40\%$ 的实践。

3. **年龄**：增龄是心血管疾病的独立危险因素。伴随年龄增长，心肌纤维化、血管僵硬增加、肾功能自然减退、合并症（如 COPD、糖尿病）增多，导致心衰患者对治疗的耐受性下降，死亡风险累积上升。本研究中年龄与死亡的相关系数最高（0.294），且两种重要性指标均列前三，证实其不可忽视的预后价值。

综上，后续风险预测模型构建与药物经济学分析应重点围绕上述三项指标展开。例如，针对血清肌酐升高者可强化利尿剂及 RAAS 拮抗剂管理；针对射血分数低下者可优先启用维立西呱或达格列净等新型药物；老年患者则需综合评估衰弱状态与治疗获益。

五、心衰患者死亡概率预测模型的构建与评估

5.1 预测模型选择与理论基础

为全面评估心衰患者死亡风险的预测性能，并兼顾模型的可解释性与泛化能力，本文选取了三类具有不同归纳偏置的机器学习算法：逻辑回归、随机森林和 XGBoost。以下分别阐述各模型的数学原理、工作机制及其在本研究中的适用性。

5.1.1 逻辑回归：广义线性模型与概率建模

逻辑回归 (Logistic Regression, LR) 是一种用于二分类问题的广义线性模型。其核心思想是将特征的线性组合通过逻辑函数 (Sigmoid) 映射到 (0,1) 区间, 直接输出样本属于正类 (死亡) 的概率。其数学原理可表示为: 设特征向量为 $\mathbf{x} \in \mathbb{R}^p$, 权重向量为 $\boldsymbol{\beta}$, 截距为 β_0 , 则死亡概率为:

$$P(y = 1 | \mathbf{x}) = \frac{1}{1 + \exp(-(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}))} \quad (4)$$

模型通过极大似然估计 (MLE) 求解参数, 目标函数为对数损失:

$$\min_{\boldsymbol{\beta}} - \sum_{i=1}^n [y_i \log \hat{y}_i + (1 - y_i) \log (1 - \hat{y}_i)] + \lambda \|\boldsymbol{\beta}\|_2^2 \quad (5)$$

其中添加的 L2 正则化项 (岭回归) 用于控制模型复杂度, 防止过拟合。

基于上述原理, 逻辑回归成为临床预测模型中最常用的基准方法, 因为它具有高度的可解释性: 各特征的权重 β_j 直接反映了该特征对死亡风险对数几率的影响方向和强度。在心衰预测任务中, 医生不仅需要获得死亡风险数值, 更希望

理解哪些因素 (如射血分数、血清肌酐) 起主导作用。因此, 本研究选择逻辑回归作为线性基线, 既为后续复杂模型提供性能参照, 又可用于初步筛选关键风险指标。

5.1.2 随机森林: Bagging 集成与决策树平均

随机森林 (Random Forest, RF) 是一种基于决策树的 Bagging 集成算法, 通过构建多棵相互独立的决策树并聚合其预测结果, 显著降低单棵决策树的方差, 从而提升泛化能力。其核心思想包含两个关键随机化策略: 一是 Bootstrap 采样, 即从原始训练集中有放回地随机抽取与原始样本量相同数量的样本, 生成多个子训练集; 二是随机特征子空间, 即在每棵树的每个节点分裂时, 仅从全部特征中随机选择部分候选特征 (通常取特征总数的平方根), 从中选取最佳分裂特征。每棵决策树完全生长且不进行剪枝, 最终预测通过聚合所有树的输出得到。

对于分类任务, 设随机森林包含 K 棵决策树, 第 k 棵树对输入 $\mathbf{x}$ 的预测概率为 $\hat{p}_k(\mathbf{x})$ (即该树叶子节点中正类的比例)。随机森林输出的死亡概率为所有树的平均:

$$\hat{P}(y = 1 | \mathbf{x}) = \frac{1}{K} \sum_{k=1}^K \hat{p}_k(\mathbf{x}) \quad (6)$$

当采用多数投票法时, 分类决策为 $\hat{y} = \text{mode} \{\hat{y}_1, \hat{y}_2, \dots, \hat{y}_K\}$, 其中 $\hat{y}_k$ 为第 k 棵树的预测类别。

基于上述原理, 随机森林具备自动捕捉特征之间非线性交互与高阶组合的能力, 无需显式设计交叉项。心衰患者的死亡风险往往由多个因素的协同作用决定 (例如年龄与射血分数的交互), 随机森林天然适合此类问题。此外, 该算法对异常值和缺失值具有较强的鲁棒性, 且超参数较少、调优简单。

5.1.3 XGBoost: 梯度提升与二阶优化

XGBoost (eXtreme Gradient Boosting) 是梯度提升决策树 (GBDT) 的一种高效实现。与随机森林并行训练多棵树不同, XGBoost 采用序列式集成策略: 每一棵新树都试图拟合前一棵树预测的残差, 并通过累加所有树的贡献逐步改进预测。其核心思想是在每一轮迭代中优化一个带正则化的目标函数, 并利用损失函数的二阶导数信息加速收敛。

设模型由 K 棵树组成, 对第 i 个样本的预测值为 $\hat{y}_i = \sum_{k=1}^K f_k(\mathbf{x}_i)$, 其中 f_k 表示第 k 棵决策树。XGBoost 的目标函数包含训练损失和正则化项:

$$\mathcal{L} = \sum_{i=1}^n \ell(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (7)$$

其中 ℓ 为对数损失函数, $\Omega(f)$ 为树的复杂度惩罚项, 定义为:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2 \quad (8)$$

这里 T 为树的叶节点数, $\mathbf{w}$ 为各叶节点的权重 (即预测分数), γ 和 λ 为正则化参数。在每一步迭代中, XGBoost 对损失函数进行二阶泰勒展开, 并求解使目标函数最小的树结构。

基于上述原理, XGBoost 在众多表格数据竞赛中往往取得比随机森林更高的精度。其显式正则化与树剪枝策略有助于在小样本条件下 (本例仅 299 例) 控制过拟合, 同时列采样和早停机制进一步增强了泛化能力。此外, XGBoost 支持自定义损失函数和缺失值自动学习方向, 灵活性高。本研究将 XGBoost 纳入比较, 旨在考察 Boosting 策略是否优于 Bagging 策略, 并为后续大样本扩展提供经验依据。

5.2 数据集划分与模型训练

为保证模型评估的客观性和可重复性, 本研究将预处理后的心衰患者数据集按照 8:2 的比例划分为训练集与测试集。由于数据集中死亡结局的样本比例约为 32%, 属于轻度不平衡分布, 简单随机划分可能导致训练集或测试集中死亡样本比例偏离总体分布。为此, 采用分层随机抽样策略, 以结局标签 (存活/死亡) 为分层变量, 确保训练集和测试集中两类样本的比例与原始数据保持一致。总样本量为 299 例, 最终训练集包含 239 例 (80%), 其中存活 162 例、死亡 77 例; 测试集包含 60 例 (20%), 其中存活 41 例、死亡 19 例。这一划分结果与后续混淆矩阵中反推的实际测试样本数完全吻合, 验证了划分的一致性。

在模型训练阶段, 三种分类器均使用训练集进行参数学习。各模型采用的具体超参数设置如下, 这些参数基于预实验或文献经验确定, 未进行额外的网格搜索, 以保持训练过程的简洁性和可复现性。

- 逻辑回归：采用 L2 正则化的逻辑回归模型，最大迭代次数设为 1000 以保证收敛，正则化强度参数 C 取值为 0.5（较小的 C 值对应较强的正则化），随机种子固定为 42 以确保结果可复现。该模型对特征尺度敏感，但已通过前期的 Z-score 标准化处理。
- 随机森林：构建包含 500 棵决策树的随机森林，每棵树的深度限制为 8 层，以防止过拟合。针对数据集中死亡样本较少的不平衡问题，设置类别权重为 “balanced”，使模型自动根据类别频率调整权重，提高对少数类（死亡）的敏感度。随机种子固定为 42，并启用并行计算以加速训练。
- XGBoost：采用梯度提升框架，包含 200 棵决策树，每棵树的深度设为 4，学习率取 0.05（较小的学习率配合较多的树可提升泛化能力）。为处理类别不平衡，将正类（死亡）的权重比例设为训练集中负类与正类样本数的比值（即约 2.1:1）。评估指标采用对数损失，随机种子固定为 42，训练过程不输出冗长信息。

所有模型在训练集上完成参数学习后，对测试集样本分别输出死亡概率和二分类预测标签（默认阈值为 0.5）。上述训练流程确保了模型比较的公平性：三种模型共享完全相同的训练集和测试集，且均以原始特征输入（未经特征选择），以评估各自在完整特征空间下的预测能力。

5.3 模型性能评估与对比分析

为全面比较逻辑回归、随机森林与 XGBoost 三种模型对心衰患者死亡风险的预测能力，本研究采用多项分类评价指标，包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数以及 ROC 曲线下面积（AUC）。所有指标均在相同的测试集（N=60，其中存活 41 例，死亡 19 例）上计算，确保结果可比性。如图展示了各模型的混淆矩阵，ROC 曲线，并汇总了关键性能指标。

5.3.1 混淆矩阵与基础分类指标

混淆矩阵直观反映了模型对正负类的判别结果。根据图示结果，逻辑回归正确预测了 35 例存活（占存活样本的 85.4%）和 12 例死亡（占死亡样本的 63.2%），误将 7 例存活预测为死亡，6 例死亡预测为存活。随机森林正确预测了 36 例存活（87.8%）和 12 例死亡（63.2%），误判情况与逻辑回归相近，但多正确识别了 1 例存活。XGBoost 正确预测了 33 例存活（80.5%）和 10 例死亡（52.6%），误报死亡 9 例，漏报死亡 8 例，在死亡样本上的识别能力相对较弱。

从基础指标来看，随机森林在准确率和精确率上均略优于逻辑回归和 XGBoost。在召回率方面，逻辑回归与随机森林均为 0.3684，即仅能识别出约 36.8% 的实际死亡患者；XGBoost 的召回率最高，但这是以牺牲精确率为代价的——其精确率仅为 0.5294，意味着有近一半的死亡预测属于误报。F1 分数作为精确率与召回率的调和均值，XGBoost 略高于随机森林和逻辑回归，反映了不同模型在平衡漏报与误报上的权衡。




图 6 三模型分类效果混淆矩阵

表 4 各模型分类性能指标对比

模型	AUC	准确率	精确率	召回率	F1 分数
Logistic Regression	0.7522	0.7000	0.5385	0.3684	0.4375
Random Forest	0.7933	0.7167	0.5833	0.3684	0.4516
XGBoost	0.7317	0.7000	0.5294	0.4737	0.5000

5.3.2 ROC 曲线与 AUC 值

ROC 曲线通过绘制不同分类阈值下的真阳性率（召回率）与假阳性率，全面评价模型对正负样本的排序能力。由图 7 可知，随机森林的 ROC 曲线最靠近左上角，其 AUC 值达到 0.7933，在三种模型中最高；逻辑回归次之，AUC 为 0.7522；XGBoost 的 AUC 为 0.7317，排序能力相对最低。AUC 值表明，随机森林在随机抽取一对存活与死亡患者时，能够以 79.33% 的概率将死亡患者赋予更高的风险评分，优于其他两个模型。

值得注意的是，虽然随机森林与逻辑回归在默认阈值（0.5）下的召回率完全相同（均为 0.3684），但随机森林的 AUC 显著更高，说明其输出的概率在整体排序质量上优于逻辑回归。换言之，随机森林对死亡患者给出的风险概率值往往更集中在高区间，而对存活患者给出的概率更集中在低区间，只是当采用 0.5 作为判别阈值时，二者的二分类结果恰好一致。XGBoost 的召回率虽高，但 AUC 最低，提示其概率排序能力有限——部分存活患者可能被赋予了高于死亡患者的风险评分，导致曲线下方面积下降。

5.3.3 综合比较与模型优选

综合各项指标，随机森林在 AUC（0.7933）、准确率（0.7167）和精确率（0.5833）上均取得最优值，F1 分数（0.4516）与逻辑回归相近。尽管其召回率（0.3684）偏低，但这一现象主要源于数据集固有的类别不平衡（死亡样本仅占测试集 31.7%）以及临床预测任务的保守倾向——模型更倾向于将不确定的样本预测为多数类（存活）。在实际临




图 7 ROC 曲线对比

床应用中，可通过调整分类阈值（例如降低至 0.3）来提高召回率，以优先识别高风险患者，但与此同时误报率也会相应上升。

逻辑回归作为线性基准模型，取得了中等性能，其在 AUC 和精确率上均优于 XGBoost，表明简单的线性决策边界在此问题上并非明显劣势。XGBoost 在默认阈值下表现出最高的召回率，但 AUC 最低且精确率最低，说明其概率校准可能不够理想，或在小样本条件下 Boosting 策略产生了过拟合。因此，从整体区分能力和概率排序质量出发，随机森林是本研究中预测心衰患者死亡风险的最优模型。

六、个体化死亡概率预测与风险分层验证

基于前述模型性能评估结果，随机森林在区分心衰患者死亡风险方面表现最优 (AUC=0.7933)。为进一步验证其临床实用性，本研究从两个维度展开分析：一是评估模型对测试集全体患者的风险分层能力，二是选取三个典型个体输出死亡概率，展示模型在个体化预测中的应用价值。

6.1 风险分层能力验证

将测试集中 60 例患者经随机森林模型输出的死亡概率按照预设阈值划分为三个风险层级：低风险（概率 < 0.30）、中风险（0.30 ≤ 概率 ≤ 0.70）和高风险（概率 > 0.70）。下图展示了各风险组患者的实际死亡率分布。结果显示，低风险组共 32 例患者，其中仅 4 例死亡，实际死亡率为 12.5%；中风险组 23 例患者，12 例死亡，死亡率为 52.2%；高风险组 5 例患者，3 例死亡，死亡率为 60.0%。随着预测风险等级从低到高，实际死亡率呈现严格单调递增的趋势。这一结果证实随机森林模型输出的概率不仅具有良好的排序能力，而且能够有效将患者区分为具有显著预后差异的亚组。在临床实践中，低风险患者可考虑适当延长随访问隔或采用保守管理策略，而中高风险患者则需加强监测并及时调整治疗方案。

6.2 个体化预测示例

为直观展示模型对新患者的预测能力，选取三例具有典型临床特征的心衰患者，其临床指标基于识别的关键风险因素（射血分数、血清肌酐、年龄）进行设定，其他特征取训练集相应分布的代表性值。各患者的特征描述及预测结果如下：




图 8 风险分层与患者预测

患者 A (低风险): 该患者年龄较轻 (52 岁)，射血分数处于正常范围 (58%)，血清肌酐水平正常 (0.9 mg/dL)，无贫血、无高血压。随机森林模型预测其死亡概率为 0.1170，归属低风险组 (<0.30)。该预测符合临床预期：年轻、心功能保留、肾功能正常且无合并症的患者预后良好。

患者 B (中风险): 该患者为中年 (65 岁)，射血分数轻度降低 (38%)，血清肌酐轻度升高 (1.4 mg/dL)，伴有贫血但无高血压。模型预测死亡概率为 0.4384，处于中风险区间 (0.30–0.70)。此类患者心功能处于临界状态，肾功能亦有轻度损害，死亡风险居中，需定期随访并评估病情进展。

患者 C (高风险): 该患者高龄 (81 岁), 射血分数显著降低 (22%), 血清肌酐升高至 2.1 mg/dL, 同时伴有低钠血症 (128 mEq/L)、贫血和高血压。模型预测死亡概率高达 0.8401, 归为高风险组 (>0.70)。该患者具有多重不良预后因素: 重度心力衰竭 (射血分数 <25%)、肾功能不全、电解质紊乱及多种合并症, 其高风险预测与临床先验知识高度一致。

表 5 新患者特征描述及随机森林模型预测结果

患者	年龄 (岁)	射血分数 (%)	血清肌酐 (mg/dL)	其他关键特征	死亡概率	风险等级
患者 A	52	58	0.9	无贫血、无高血压	0.1170	低风险
患者 B	65	38	1.4	贫血、无高血压	0.4384	中风险
患者 C	81	22	2.1	贫血、高血压、低血钠	0.8401	高风险

上述示例表明, 随机森林模型能够整合多维临床指标, 输出个体化的死亡风险概率, 且预测结果与各因素对应的病理生理机制相符。在实际临床决策中, 医生可设定适当的风险阈值 (如 0.30 和 0.70) 将患者分流至不同管理路径: 对于概率低于 0.30 的患者, 可维持常规治疗; 对于概率介于 0.30 至 0.70 的患者, 应加强随访频率并考虑优化药物治疗; 对于概率高于 0.70 的患者, 则需紧急干预并制定更为积极的治疗策略。这种基于机器学习模型的个体化风险评估方法, 为心衰患者的精准分层和预后管理提供了定量化工具。

七、 讨论与推广

本研究基于真实世界的心力衰竭临床随访数据, 系统构建了包含数据预处理、风险因子识别、模型训练与评估、个体化预测在内的生存预测框架。通过对比逻辑回归、随机森林与 XGBoost 三种主流机器学习算法, 验证了集成学习模型在心衰患者死亡风险预测中的优势, 并识别出血清肌酐、射血分数与年龄为三大核心风险因子。以下从模型性能、临床可解释性、方法学局限及推广潜力等方面进行深入讨论。

7.1 模型性能的比较与解释

从预测性能来看, 随机森林在 AUC (0.7933)、准确率 (0.7167) 和精确率 (0.5833) 三项指标上均优于逻辑回归与 XGBoost, 表明其在处理心衰数据中常见的非线性关系、特征交互及阈值效应方面具有更强的建模能力。尤其在 AUC 这一对类别不平衡不敏感的综合排序指标上, 随机森林的优势更为明显, 说明其输出的死亡概率具有良好的区分度。

逻辑回归作为线性基准模型，AUC 达到 0.7522，显著优于随机猜测，且与随机森林的差距并不悬殊。这一结果提示，部分风险因素与死亡结局之间可能存在近似线性的关系，例如年龄和贫血。逻辑回归的高可解释性使其在临床实践中仍具有重要价值，尤其是在需要明确各因素对风险贡献方向（正向或负向）的场景中。

XGBoost 在本研究中的表现相对逊色，AUC 仅为 0.7317，且精确率偏低。可能原因包括：第一，样本量较小（仅 299 例），Boosting 策略在迭代拟合残差过程中容易放大噪声，导致过拟合；第二，超参数未进行系统调优，可能未达到最佳状态；第三，心衰数据中存在部分异常值，虽然树模型对异常值鲁棒，但 Boosting 序列结构可能仍受异常样本影响。因此，在小样本医学数据中，Bagging 策略（如随机森林）可能优于 Boosting 策略，值得后续研究进一步验证。

7.2 核心风险因子的临床意义

通过相关性分析与随机森林特征重要性评估，本研究一致识别出血清肌酐、射血分数与年龄为心衰患者死亡风险的三大核心预测因子。这一结果与当前心力衰竭临床指南中的危险分层标准高度吻合。

血清肌酐 在随机森林中重要性最高，但其 Pearson 相关系数为负 (-0.269)，这一看似矛盾的结果揭示了线性与非线性建模的本质差异。血清肌酐与死亡风险之间并非单调线性关系：极低肌酐提示营养不良或肌肉萎缩，预后同样不良；中高肌酐反映肾灌注不足或心肾综合征；极高值提示急性肾损伤。随机森林成功捕捉了这一 U 型或阈值型关系，而线性模型无法刻画。临床实践中，应关注肌酐的动态变化及与其他指标（如年龄、射血分数）的交互作用。

射血分数 在相关性分析中几乎为零 ($r = 0.063$)，但在随机森林中重要性位列第二。这一结果有力证明了射血分数作为心衰核心病理生理指标的价值并未消失，而是其效应呈现为非线性分段形式。例如，射血分数 $\leq 30\%$ 的患者死亡风险显著高于射血分数 $30\%-40\%$ 的患者，而射血分数正常 ($\geq 50\%$) 的患者风险最低。线性相关无法捕捉这种“拐点”效应，而树模型天然适合此类阈值型关系。

年龄 在相关性分析与随机森林中均稳居前三，且与死亡的相关系数最高 (0.294)，说明增龄本身即为独立危险因素，且其效应在一定程度上呈线性递增趋势。年龄的持续性重要性提示，在心衰管理中，应重视老年患者的综合评估，包括衰弱、多病共存及药物耐受性。

7.3 方法学优势与局限

本研究的方法学优势主要体现在以下几个方面：第一，采用了完整的预处理流程，包括 IQR 异常值检测、Z-score 标准化及分层抽样划分数据集，确保数据质量与模型训练的科学性；第二，融合了线性相关性分析与树模型特征重要性两种互补方法，兼顾线

性与非线性风险因子的识别；第三，采用多指标（准确率、精确率、召回率、F1、AUC）评估模型性能，避免单一指标带来的评价偏差；第四，通过个体化预测示例与风险分层验证，增强了模型的临床可操作性。

然而，本研究也存在若干局限性，需在后续研究中予以关注：

1. 样本量有限：总样本仅 299 例，测试集仅 60 例，导致部分评价指标（如召回率）波动较大。尽管采用了分层抽样与类别权重调整，但仍存在过拟合风险。未来应在大样本、多中心数据集中验证模型稳定性。

2. 缺乏外部验证：模型仅在单一数据集的测试集上评估，未采用独立的外部验证集或交叉验证策略。外部验证是评估模型泛化能力的金标准，后续应引入不同机构、不同地区的心衰队列进行验证。

3. 随访时间（time）变量的处理方式：本研究在特征重要性评估与模型构建中剔除了 time 变量，以避免因果倒置（随访时间越长，死亡概率越高）。但在实际临床决策中，time 本身是重要的生存信息。未来可考虑引入生存分析模型（如随机生存森林、Cox 比例风险模型），将随访时间作为核心变量，直接预测时间依赖性死亡风险。

7.4 模型的推广与临床转化潜力

尽管存在上述局限，本研究所构建的随机森林模型仍具有较强的临床转化潜力。首先，模型输入变量均为心衰患者常规采集的临床指标（年龄、射血分数、血清肌酐等），无需额外检查或成本，易于集成至电子病历系统。其次，模型输出为个体化的死亡概率（0~1 连续值），比二分类结果提供更丰富的信息，可支持动态风险分层。例如，临床医生可根据概率值设定个性化的随访频率、药物强度或转诊时机。最后，本研究公开了模型的关键参数与决策逻辑（如特征重要性排序），具备一定的可解释性，有助于增强临床医生的信任度。

未来推广方向包括：开发基于 Web 的简易计算器或可视化仪表盘，供医生实时输入患者信息并获取死亡风险概率；将模型嵌入医院信息系统的临床决策支持模块，实现自动风险预警；结合药物经济学分析，评估针对不同风险层级的干预措施的成本效果比。

八、结论

本研究基于心力衰竭患者的真实临床随访数据，系统构建了涵盖数据预处理、风险因子识别、模型训练与评估、个体化预测的生存风险预测框架，得出以下主要结论：

- **随机森林模型在心衰患者死亡风险预测中表现最优**，其 AUC 达到 0.7933，准确率为 0.7167，显著优于逻辑回归（AUC=0.7522）与 XGBoost（AUC=0.7317），表明集成学习中 Bagging 策略在小样本心衰数据中优于 Boosting 策略。

- **血清肌酐、射血分数与年龄是心衰患者死亡的三大核心风险因子。**其中，血清肌酐在随机森林中重要性最高，但其线性相关性为负，反映出非线性 U 型或阈值效应；射血分数线性相关极弱但重要性高，验证了其作为非线性分段风险因子的病理生理价值；年龄在线性与非线性评估中均表现稳定，是独立且持续的危险因素。
- **线性模型与树模型的结合有助于全面识别风险因素。**Pearson 相关系数捕捉线性趋势，随机森林特征重要性挖掘非线性交互与阈值效应，两者互补提高了风险因子筛选的稳健性。
- **随机森林模型能够实现有效的风险分层与个体化预测。**低、中、高风险组的实际死亡率呈严格单调递增（12.5%、52.2%、60.0%），且典型病例的预测概率与临床先验知识高度一致，验证了模型的临床实用性。
- **当前模型仍存在样本量有限、缺乏外部验证、召回率偏低等局限**，未来需在多中心、大样本队列中进行外部验证，并引入生存分析框架与决策曲线分析，以进一步提升模型的泛化能力与临床决策价值。

综上所述，本研究构建的基于随机森林的心力衰竭患者死亡风险预测模型，在区分能力、临床可解释性与个体化输出方面均表现出良好性能，具备潜在的临床转化价值。该框架可为心衰患者的精准分层、随访策略制定及医疗资源优化提供量化决策支持。

参考文献

- [1] Savarese G, Lund L H. Global public health burden of heart failure[J]. Cardiac Failure Review, 2017, 3(1): 7-11.
- [2] Gheorghiade M, Vaduganathan M, Fonarow G C, et al. Rehospitalization for heart failure: problems and perspectives[J]. Journal of the American College of Cardiology, 2013, 61(4): 391-403.
- [3] Yancy C W, Jessup M, Bozkurt B, et al. 2013 ACCF/AHA guideline for the management of heart failure: a report of the American College of Cardiology Foundation/American Heart Association Task Force on Practice Guidelines[J]. Circulation, 2013, 128(16): e240-e327.
- [4] Austin P C, Steyerberg E W. The number of subjects per variable required in linear regression analyses[J]. Journal of Clinical Epidemiology, 2015, 68(6): 627-636.
- [5] Rajkomar A, Dean J, Kohane I. Machine learning in medicine[J]. New England Journal of Medicine, 2019, 380(14): 1347-1358.

- [6] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco, 2016: 785-794.
- [7] Tukey J W. Exploratory Data Analysis[M]. Reading: Addison-Wesley, 1977: 39-51.
- [8] Smith G L, Shlipak M G, Havranek E P, et al. Serum creatinine and risk of cardiovascular events in patients with heart failure[J]. Journal of Cardiac Failure, 2006, 12(6): 464-470.